# Siapa yang harus dihubungi tim retensi bulan ini?

Model prediksi churn untuk perusahaan telekomunikasi dengan anggaran retensi terbatas. Dengan menghubungi 20% pelanggan berisiko tertinggi, **51% pelanggan yang akan churn tertangkap**.


| Disusun oleh | NIM | Kelas | Data | Program studi |
|---|---|---|---|---|
| **Titanio Yudista** | **24120500031** | **A** | **Telco Customer Churn (IBM)** | **Sains Data, Universitas Cakrawala** |


Repositori kode dan notebook
**github.com/titan2903/uas-predictive-analytics**

# Satu dari empat pelanggan berhenti, padahal tim retensi hanya sanggup menghubungi 20% pelanggan

Data historis mencatat **1.869 dari 7.043 pelanggan (26,5%)** berhenti berlangganan. Yang pergi justru pelanggan bernilai: rata-rata tagihannya **USD 74** per bulan, dibanding USD 61 pada pelanggan yang bertahan.

Klien perlu memutuskan siapa yang dihubungi lebih dulu, supaya anggaran retensi tidak terpakai untuk pelanggan yang memang akan bertahan, dan kebijakan apa yang bisa mencegah churn sejak awal.

| Ukuran keberhasilan | Definisi dan alasan |
|---|---|
| **PR-AUC**<br>metrik model | Seberapa tepat model meranking pelanggan berisiko. Accuracy tidak dipakai: menebak "tidak churn" untuk semua pelanggan saja sudah menghasilkan 73,5%. |
| **Net saved revenue**<br>metrik bisnis | Churner yang dihubungi × tagihan bulanan × 12 bulan × success rate 30%, dikurangi biaya penawaran USD 35,15 per kontak. |
| **Lift pada top-20%**<br>metrik operasional | Berapa kali lebih tepat sasaran dibanding menghubungi pelanggan secara acak, pada kapasitas yang sama. |

# Data relatif bersih, dan semua masalahnya diperbaiki tanpa membuang satu baris pun

**7.043** pelanggan, **21** kolom: profil, layanan, kontrak, tagihan, dan target *Churn*.

Tidak ada nilai NaN, duplikat customerID, maupun outlier IQR.

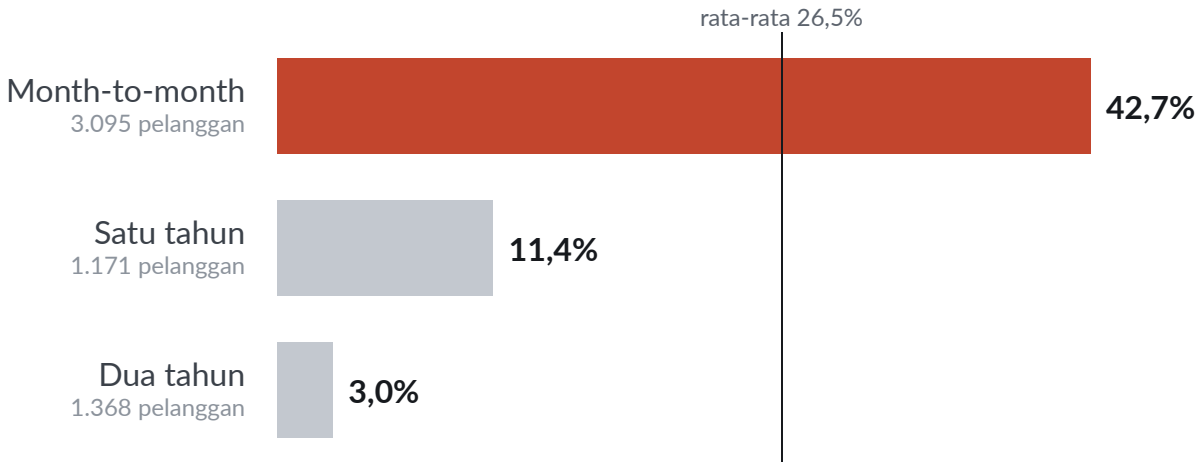
Data sampel IBM yang meniru kondisi bisnis nyata. Satu snapshot, tanpa tanggal.

| Masalah yang ditemukan | Penanganan dan alasan |
|---|---|
| **11** nilai `TotalCharges` kosong, semuanya pelanggan baru (tenure 0) | Diisi 0, karena pelanggan baru memang belum pernah ditagih |
| Kategori "No internet service" dan "No phone service" di 7 kolom layanan | Digabung ke "No"; informasinya sudah ada di `InternetService` dan `PhoneService` |
| **22** baris identik di luar ID (pelanggan berbeda, profil sama) | Dipertahankan, lalu dijadikan satu grup saat split agar tidak muncul di train sekaligus test |
| **27** baris dengan TotalCharges menyimpang > 25% dari tenure × tagihan | Dipertahankan karena tarif bisa berubah; menjadi dasar fitur `charge_increase` |
| Kelas tidak seimbang, churn 26,5% | Metrik PR-AUC, bobot kelas, dan aturan kapasitas top-20% |

# Pelanggan month-to-month churn 14 kali lebih sering daripada pelanggan kontrak dua tahun

**Churn rate per jenis kontrak**

Persentase pelanggan yang berhenti, data train (n = 5.634)



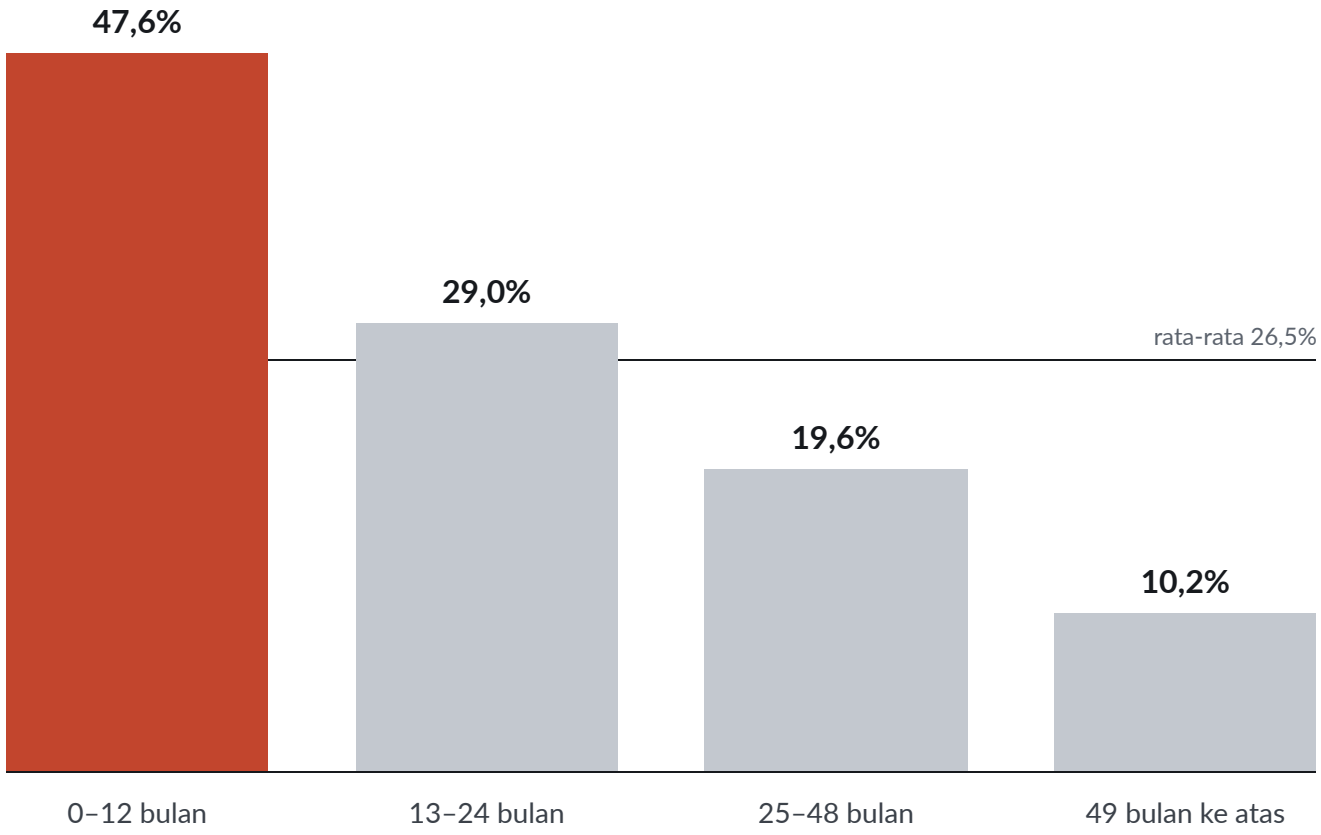

**Implikasi**

Month-to-month adalah segmen terbesar (55% pelanggan) sekaligus paling berisiko. Begitu pelanggan terikat kontrak, risikonya turun tajam. Jenis kontrak adalah tuas retensi paling kuat, dan menjadi dasar rekomendasi migrasi ke kontrak satu tahun.

# Risiko churn terkonsentrasi di tahun pertama berlangganan

**Churn rate per lama berlangganan**

Data train (n = 5.634)



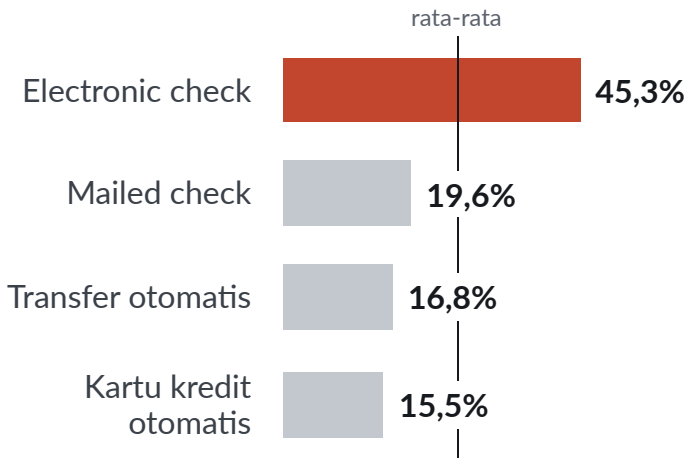

**Implikasi**

Median lama berlangganan pelanggan yang churn hanya **10 bulan**, dibanding **37 bulan** pada yang bertahan. Risiko di tahun pertama 4,7 kali risiko pelanggan lama. Onboarding dan kontak proaktif di 12 bulan pertama memberi peluang retensi terbesar.

# Pembayaran electronic check dan layanan fiber optic menandai pelanggan yang paling mudah pergi

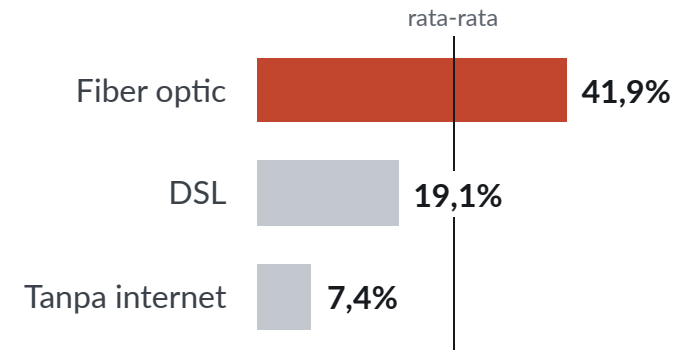
**Churn rate per metode pembayaran**

Data train




**Churn rate per layanan internet**

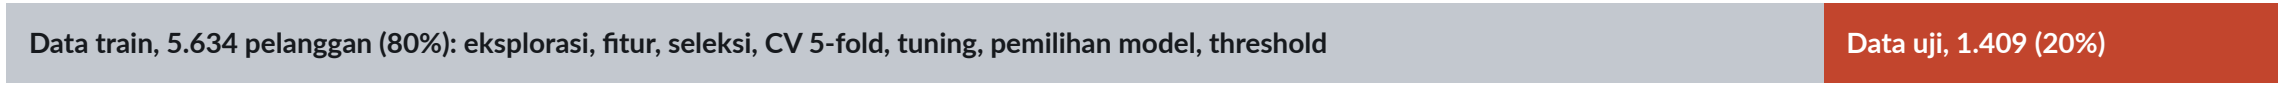
Data train




**Implikasi**

Kombinasi month-to-month dan electronic check mencatat churn **53,4%** dan mencakup 25,9% pelanggan. Di antara pengguna internet, churn turun dari 54,4% (tanpa add-on) ke 6,4% (enam add-on). Pembayaran otomatis dan bundling layanan menaikkan biaya untuk pindah.

# Data uji disisihkan sejak awal dan baru dibuka setelah semua keputusan dikunci




Split stratified berbasis grup dilakukan sebelum eksplorasi data, sehingga 22 baris identik tidak terpecah ke dua sisi.

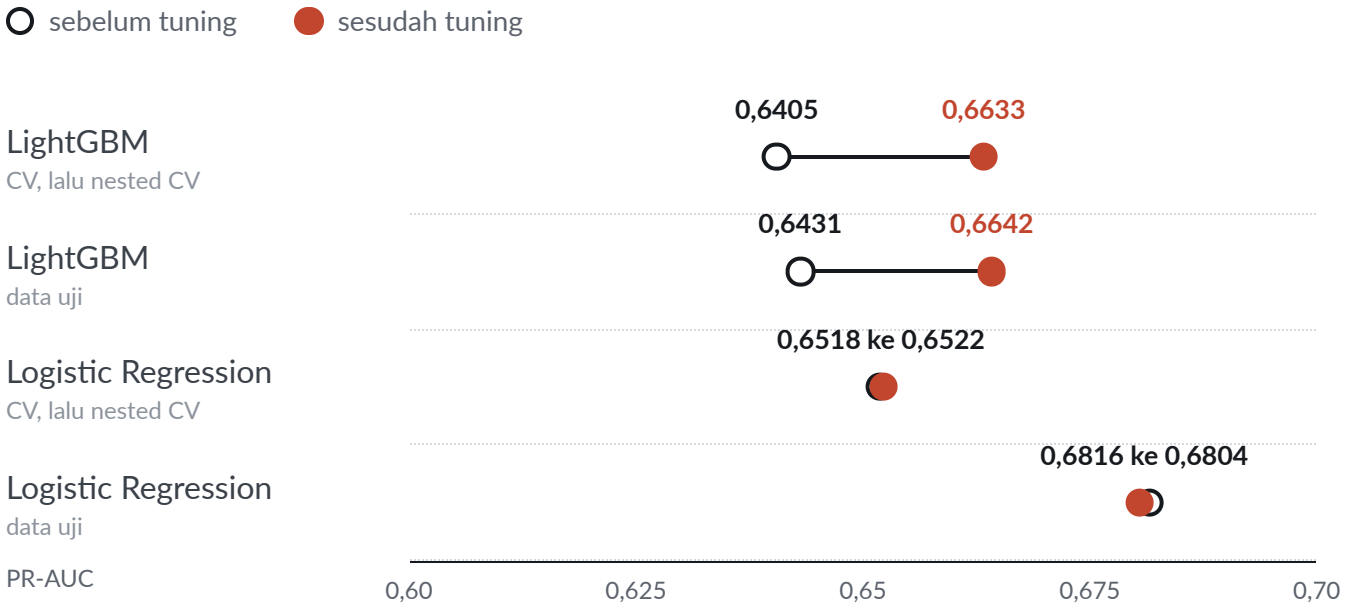
1. **Cleaning per baris.** Konversi tipe, isi nilai kosong, gabung kategori, tanpa statistik dari baris lain.
2. **Delapan fitur baru**, dihitung per baris di dalam pipeline. Satu dibuang karena kolinear; 25 fitur final.
3. **Pipeline dan CV 5-fold.** Encoder dan scaler di-fit ulang di setiap fold; semua model memakai fold yang sama.
4. **Tuning dengan nested CV**, agar skor sesudah tuning tidak bias optimis.
5. **Imbalance.** Bobot kelas, ditambah aturan operasional: hubungi 20% skor tertinggi. Threshold 0,5 ditolak karena menandai 41% pelanggan.
6. **Kunci keputusan.** Model final dan aturan kapasitas ditetapkan dari skor out-of-fold data train.
7. **Evaluasi akhir.** Data uji dibuka sekali; semua model dievaluasi dan keputusan tidak diubah.

# Semua model machine learning 1,6 kali lebih tepat sasaran daripada aturan berbasis kontrak

| Model | PR-AUC, data uji | PR-AUC, CV | Precision pada top-20% | Waktu fit | Interpretabilitas |
|---|---|---|---|---|---|
| Dummy (acak) | 0,2654 | 0,2654 | 24,8% | 0,04 dtk | tinggi |
| Aturan: kontrak saja | 0,4173 | 0,4150 | 40,1% | 0,02 dtk | tinggi |
| Random Forest | 0,6066 | 0,6162 | 65,2% | 0,58 dtk | rendah |
| LightGBM | 0,6431 | 0,6405 | 68,1% | 0,12 dtk | rendah–sedang |
| Logistic Regression | 0,6816 | 0,6518 | 69,5% | 0,07 dtk | tinggi (odds ratio) |
| Logistic Regression, tuned | 0,6804 | 0,6522 | 69,9% | 1,22 dtk | tinggi (odds ratio) |
| **LightGBM, tuned (model final)** | **0,6642** | **0,6633** | **67,7%** | **0,31 dtk** | **rendah–sedang** |

PR-AUC 0,66 berbanding 0,27 untuk pilihan acak. Precision 67,7% berarti dua dari tiga pelanggan yang dihubungi memang akan churn. CV adalah rata-rata lima fold data train dan menjadi dasar keputusan; data uji dibuka sekali. Waktu fit diukur sekali dan bisa sedikit berbeda antar eksekusi.

# Tuning menaikkan PR-AUC LightGBM sebesar 0,023, sementara Logistic Regression sudah mentok




**Metode**

RandomizedSearchCV dengan target PR-AUC: 40 kombinasi untuk LightGBM, 30 untuk Logistic Regression. Skor sesudah tuning diukur dengan nested CV.

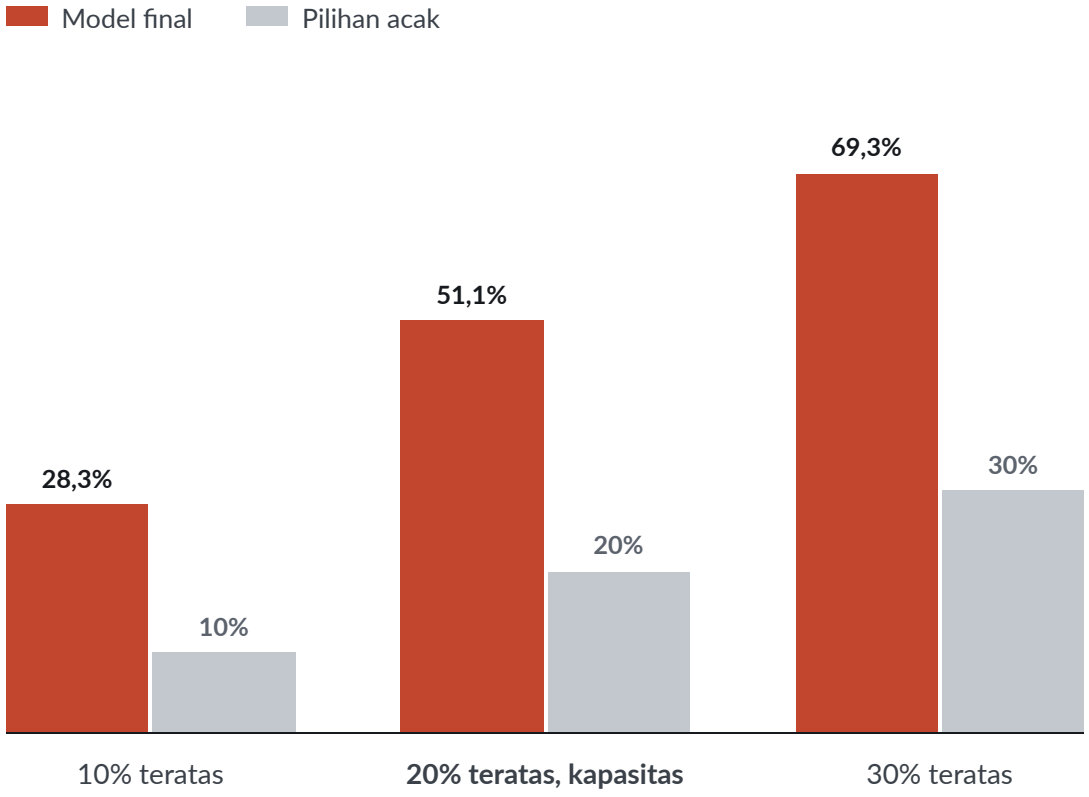
**Parameter terbaik LightGBM**

Pohon sangat dangkal (6 daun), learning rate 0,014, 307 pohon, regularisasi L2 4,82. Pengaturan bawaan terlalu kompleks untuk sekitar 5.600 baris data.

# Dengan menghubungi 20% pelanggan berisiko tertinggi, model menangkap 51% dari semua churner

### Persentase churner yang tertangkap

Menurut persentase pelanggan yang dihubungi, data uji (374 churner)




| | Dihubungi | Tidak dihubungi |
|---|---|---|
| Churn | **191** tertangkap | **183** lolos |
| Bertahan | **91** salah sasaran | **944** benar dilewati |

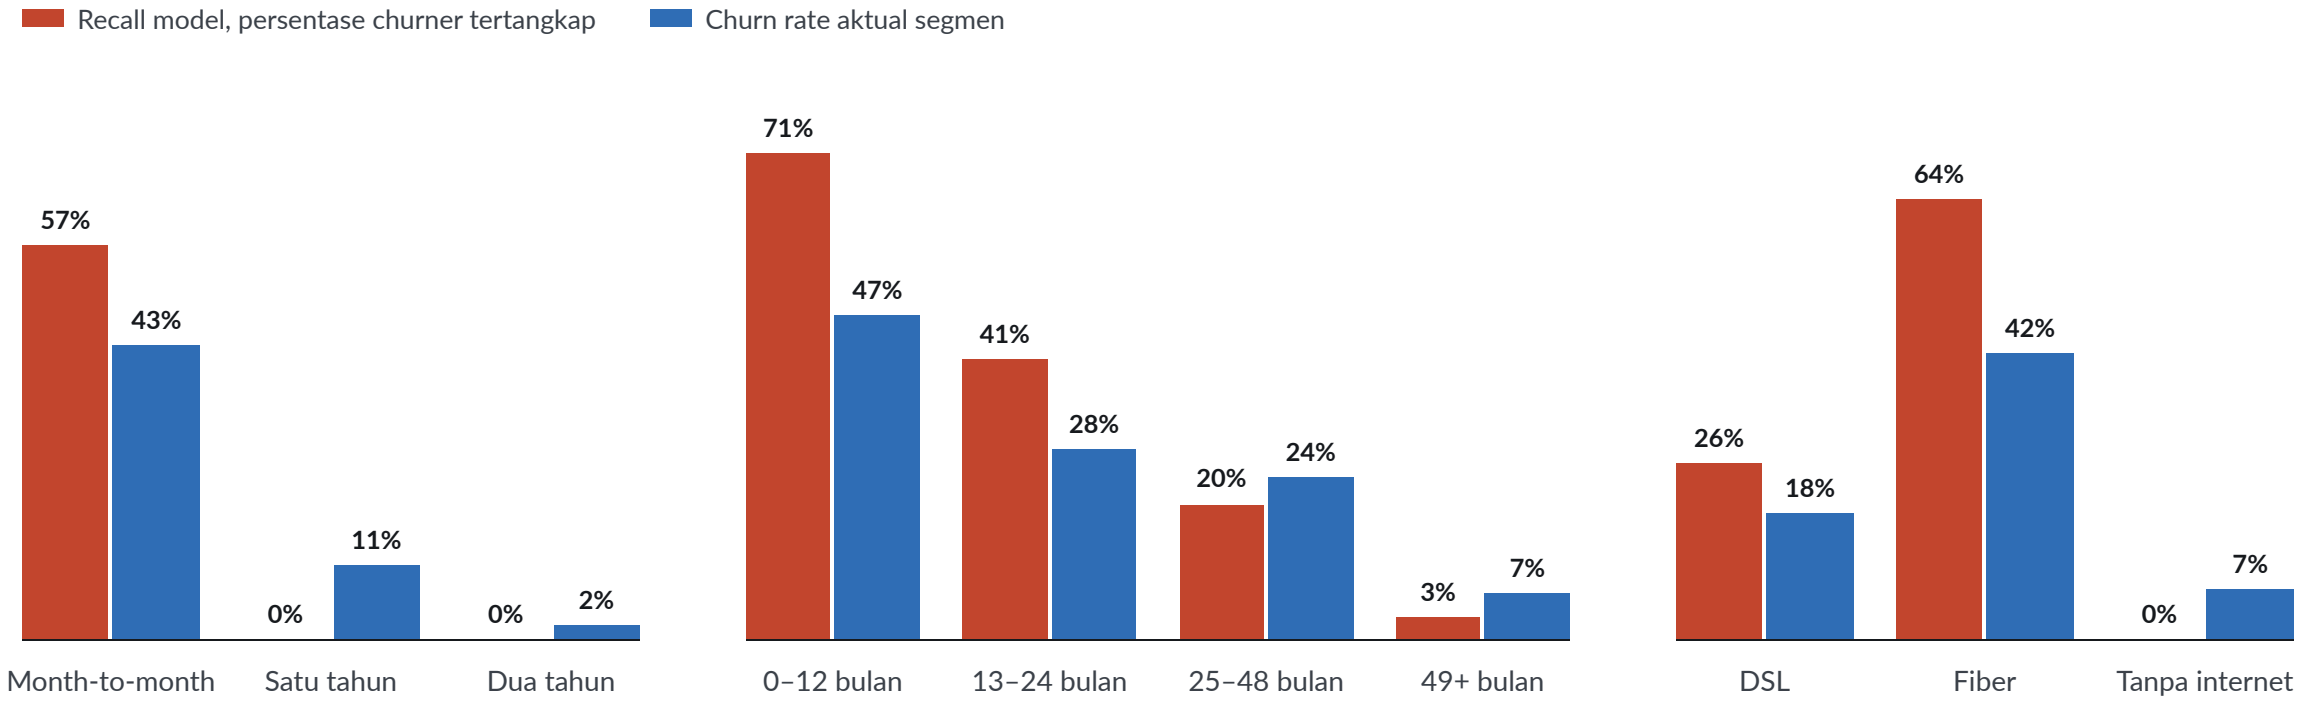
Precision **67,7%**: dua dari tiga kontak tepat sasaran. Lift **2,55 kali** dibanding acak, dan 2,83 kali pada 10% teratas.

### Mengapa LightGBM

Aturan yang dikunci sebelum data uji dibuka: pilih PR-AUC CV tertinggi, kecuali Logistic Regression berada dalam selisih 0,01. Selisihnya 0,0111. Di data uji Logistic Regression justru unggul 0,016, masih dalam variasi antar-fold (±0,019), sehingga model itu dipantau sebagai challenger.

Aturan kapasitas setara skor ≥ 0,7221. Recall 51,1%, F1 0,582, ROC-AUC 0,8577, PR-AUC 0,6642.

# Churner berkontrak panjang dan yang sudah lama berlangganan paling sering tidak tertangkap model

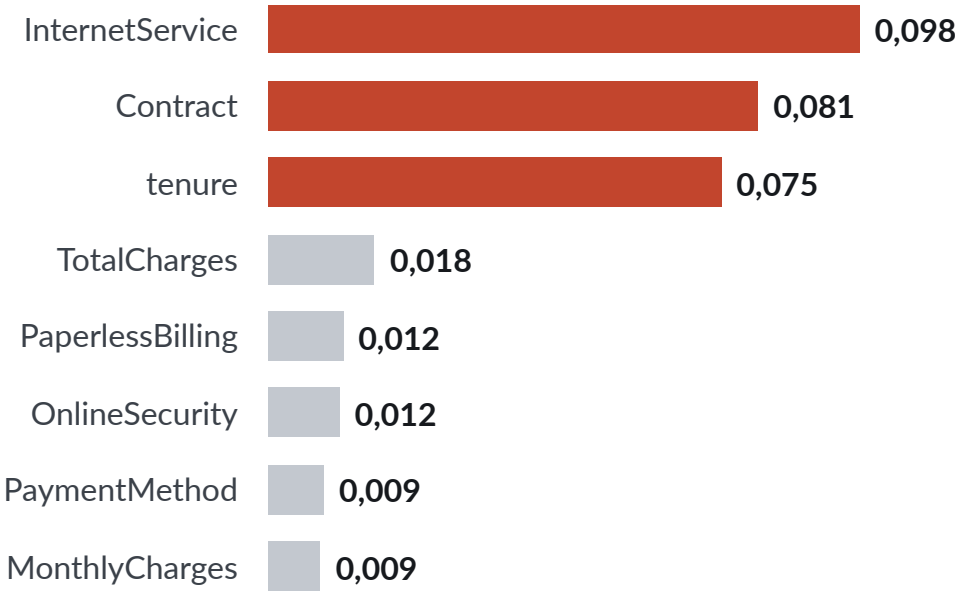



**183 churner lolos.** Median lama berlangganan mereka 24 bulan, dibanding 4 bulan pada yang tertangkap; 78% month-to-month (yang tertangkap 100%) dan 52% fiber (yang tertangkap 88%). Satu churner yang lolos merugikan sekitar USD 232, sedangkan satu kontak yang salah sasaran hanya USD 35. Pelanggan berkontrak panjang butuh program ringan tersendiri, misalnya pengingat sebelum kontrak habis, dan data keluhan.

# Jenis layanan internet, kontrak, dan lama berlangganan paling menentukan risiko churn

**Seberapa besar model bergantung pada setiap kolom**

Penurunan PR-AUC saat kolom diacak, model final, data uji




| Faktor | Arah efek (odds ratio) | Arti bisnis |
|---|---|---|
| **Internet** | Fiber 3,23 kali dibanding DSL | Nilai atau kualitas paket fiber perlu ditinjau |
| **Kontrak** | Dua tahun 0,21 kali, satu tahun 0,46 kali | Kontrak panjang memangkas odds churn 54–79% |
| **Tenure** | 0,24 kali per tambahan 24,5 bulan | Risiko tertinggi ada di tahun pertama |
| **TotalCharges** | 1,73 kali per kenaikan 1 SD | Pada tenure sama, tagihan naik berarti risiko naik |
| **Paperless billing** | 1,36 kali | Sinyal pelanggan yang mudah pindah |

Odds ratio diambil dari Logistic Regression (tuned) sebagai model pendamping untuk membaca arah efek. Efeknya kondisional dan tidak kausal. Kategori acuan: DSL dan month-to-month.

# Kampanye berbasis model menjadi prioritas pertama, dengan nilai USD 229 ribu per siklus

| | | |
|---|---|---|
| 1 | **Hubungi 20% pelanggan dengan skor risiko tertinggi setiap bulan**<br>1.410 pelanggan per siklus. Lebih baik USD 125.657 dibanding memprioritaskan berdasarkan kontrak saja. | 229.338<br>USD per siklus |
| 2 | **Tawarkan migrasi ke kontrak satu tahun dengan diskon bulan pertama**<br>3.869 pelanggan month-to-month; churn 43% dibanding 11% pada kontrak satu tahun. | 69.152<br>USD per siklus |
| 3 | **Perluas kapasitas kontak dari 20% ke 30% lewat kanal murah seperti SMS dan e-mail**<br>704 pelanggan tambahan per siklus. Kurva profit baru mencapai puncak di sekitar 56%. | 68.570<br>USD per siklus |
| 4 | **Beri insentif USD 10 untuk pindah dari electronic check ke auto-debit**<br>2.315 pelanggan; churn 45% dibanding 16% pada pembayaran otomatis. | 57.029<br>USD per siklus |

Asumsi: success rate retensi 30%, horizon revenue 12 bulan, biaya penawaran USD 35,15 per kontak (diskon 50% dari median tagihan, satu bulan). Rekomendasi 2 dan 4: adopsi 20%, dan hanya separuh selisih churn rate dianggap efek program karena datanya observasional. Basis 7.043 pelanggan. Segmen saling beririsan, sehingga nilainya tidak boleh dijumlahkan. Lingkup rekomendasi 1 dihitung dari data uji.

# Kampanye tetap menguntungkan di semua skenario, bahkan jika biaya penawaran naik empat kali

**Net saved revenue kampanye, USD per siklus**

Baris: kapasitas kontak. Kolom: success rate retensi. Bingkai: skenario dasar.

| Kapasitas | 20% | 30% | 40% |
|---|---|---|---|
| 10% | 81.621 | 134.818 | 188.016 |
| 20% | 136.376 | 229.338 | 322.300 |
| 30% | 173.832 | 297.909 | 421.985 |

**Jika anggaran dipotong setengah**

Kapasitas turun dari 20% ke 10%, nilainya turun ke USD 134.818. Itu hanya 41% lebih rendah, karena 10% teratas adalah pelanggan dengan precision tertinggi (75,2%).

**Jika biaya penawaran naik**

Dua kali lipat (USD 70): USD 179.791. Empat kali lipat (USD 141): USD 80.696. Precision break-even hanya 13,1%, jauh di bawah precision model 67,7%.

# Model siap dipakai, tetapi asumsi bisnisnya harus divalidasi lewat pilot dengan grup kontrol

## Keterbatasan

1. Data sampel IBM berupa satu snapshot tanpa tanggal, sehingga belum bisa divalidasi berbasis waktu.
2. Success rate, biaya, dan tingkat adopsi masih asumsi; rekomendasi 2 dan 4 berbasis korelasi.
3. LightGBM dan Logistic Regression setara secara statistik; urutannya berbalik antara CV dan data uji.
4. Churner berkontrak panjang sulit ditangkap tanpa data keluhan dan pemakaian.

## Langkah berikutnya

1. **Pilot** kampanye dengan 10% grup kontrol acak untuk mengukur success rate yang sebenarnya.
2. **Scoring bulanan**, sekitar 19 detik untuk satu juta pelanggan. Retrain tiap kuartal atau saat PSI melewati 0,2 (sekarang 0,0145).
3. **Champion dan challenger.** Logistic Regression menggantikan LightGBM bila unggul PR-AUC minimal 0,01 selama tiga bulan berturut-turut.
4. **Data tambahan:** keluhan, kualitas jaringan, dan histori bulanan, lalu uplift modeling.

# Pembagian kerja dan pengungkapan penggunaan AI

| Dikerjakan mahasiswa | Bantuan Claude Code (Anthropic) | Cara verifikasi |
|---|---|---|
| 1 **Arah project.** Memilih dataset PA-1A dan arah analisis. | Menyusun rencana kerja dan checklist rubrik dari panduan UAS | Dicocokkan manual dengan bagian 3.2–3.8 dan 5 panduan |
| 2 **Keputusan bisnis dan model.** Memeriksa dan menyetujui asumsi bisnis (kapasitas 20%, success rate, horizon, biaya penawaran) serta model final. | Membangun kode notebook dan menjalankan eksperimen | Notebook dijalankan ulang dua kali; angka model identik, hanya waktu eksekusi berbeda; grafik diperiksa visual |
| 3 **Verifikasi angka.** Mencocokkan angka di insight dan deck dengan output notebook. | Menyusun draf awal insight dan deck dari output notebook, lalu penyuntingan bahasa | Setiap angka di insight dan deck dicocokkan dengan output sel; angka tidak berubah setelah penyuntingan |
| 4 **Review.** Menilai temuan code review dan audit, lalu memutuskan revisi yang diterapkan. | Code review (10 temuan diperbaiki, antara lain split berbasis grup dan nested CV) dan audit akhir terhadap rubrik, termasuk mengecek angka pada insight yang ditulis mahasiswa | Setiap temuan dicek terhadap kode; hasil dibandingkan sebelum dan sesudah |
| 5 **Menulis insight.** Menulis delapan sel insight: pemilihan model (12), threshold (13), evaluasi akhir (14), error analysis (15), dan pelajaran eksperimen (19). | | |

Tidak ada data eksternal yang dipakai dan tidak ada notebook publik yang disalin.

Project dikerjakan mahasiswa dengan bantuan AI. Setiap hasil AI diverifikasi dengan menjalankan ulang notebook dan mencocokkan angkanya dengan output sel.

# Detail teknis: fitur baru, parameter, dan asumsi bisnis

| Fitur baru | Definisi |
|---|---|
| `n_addon_services` | Jumlah layanan add-on internet yang aktif (0–6) |
| `avg_charge_per_month` | TotalCharges dibagi tenure; dibuang karena korelasi 0,996 dengan MonthlyCharges |
| `charge_increase` | MonthlyCharges dikurangi rata-rata tagihan historis |
| `tenure_group` | 0–12, 13–24, 25–48, dan 49+ bulan |
| `is_auto_payment` | Transfer bank atau kartu kredit otomatis |
| `mtm_echeck` | Month-to-month dan electronic check |
| `no_protection` | Fiber tanpa OnlineSecurity dan TechSupport |
| `family_flag` | Memiliki partner atau tanggungan |

| Asumsi bisnis | Nilai |
|---|---|
| Kapasitas tim retensi per siklus | 20% |
| Success rate retensi | 30% |
| Horizon revenue | 12 bulan |
| Biaya penawaran (50% median tagihan train, satu bulan) | USD 35,15 |
| Adopsi program rekomendasi 2 dan 4 / porsi efek kausal | 20% / 50% |
| Insentif auto-debit | USD 10 |

**LightGBM final:** n_estimators 307, learning_rate 0,014, num_leaves 6, min_child_samples 57, subsample 0,7618, colsample_bytree 0,5132, reg_lambda 4,8203, scale_pos_weight 2,769. **Logistic Regression tuned:** C 35,2048, l1_ratio 0,75, class_weight balanced. **Reproducibility:** RANDOM_STATE 42, split dan fold berbasis grup, dijalankan ulang dengan hasil identik. Kode, notebook, dan data: github.com/titan2903/uas-predictive-analytics.

# Log eksperimen, termasuk yang gagal

| Eksperimen | Hasil (PR-AUC) | Status | Pelajaran |
|---|---|---|---|
| Bobot kelas (LR) | 0,6531 ke 0,6509; recall pada 0,5 naik dari 0,522 ke 0,796 | gagal sebagian | Imbalance menyangkut berapa pelanggan yang dihubungi |
| Delapan fitur baru | LR 0,6507 ke 0,6509; LightGBM 0,6396 ke 0,6397 | gagal | Tidak menaikkan skor; tetap dipakai karena bermakna bisnis |
| Seleksi fitur | Partner dan avg_charge_per_month dibuang; naik 0,0008 | berhasil | Model lebih sederhana dengan performa setara |
| Tuning LightGBM | Nested CV 0,6405 ke 0,6633; data uji 0,6431 ke 0,6642 | berhasil | Regularisasi mengurangi overfit |
| Tuning Logistic Regression | Nested CV 0,6518 ke 0,6522; data uji 0,6816 ke 0,6804 | gagal | Batas performa ada di data |
| Threshold 0,5 | Menandai 41% pelanggan, padahal kapasitas 20% | gagal | Tidak bisa dijalankan; diganti aturan 20% teratas |
| Random Forest bawaan | 0,6162, dibanding LR 0,6518 | gagal | Overfit pada sekitar 5.600 baris |
| Pemilihan model | CV: LightGBM unggul 0,0111; data uji: LR unggul 0,0162 | setara | Keputusan dikunci; LR menjadi challenger |