Siapa yang harus dihubungi tim retensi bulan ini?

Model prediksi churn untuk perusahaan telekomunikasi dengan anggaran retensi terbatas. Dengan menghubungi 20% pelanggan berisiko tertinggi, **51% pelanggan yang akan churn tertangkap**.

Disusun oleh	NIM	Kelas	Data	Program studi
Titanio Yudista	**24120500031**	**A**	**Telco Customer Churn (IBM)**	**Sains Data, Universitas Cakrawala**

Repositori kode dan notebook
github.com/titan2903/uas-predictive-analytics

Satu dari empat pelanggan berhenti, padahal tim retensi hanya sanggup menghubungi 20% pelanggan

Data historis mencatat **1.869 dari 7.043 pelanggan (26,5%)** berhenti berlangganan. Yang pergi justru pelanggan bernilai: rata-rata tagihannya **USD 74** per bulan, dibanding USD 61 pada pelanggan yang bertahan.

Klien perlu memutuskan siapa yang dihubungi lebih dulu, supaya anggaran retensi tidak terpakai untuk pelanggan yang memang akan bertahan, dan kebijakan apa yang bisa mencegah churn sejak awal.

Ukuran keberhasilan	Definisi dan alasan
PR-AUC metrik model	Seberapa tepat model meranking pelanggan berisiko. Accuracy tidak dipakai: menebak "tidak churn" untuk semua pelanggan saja sudah menghasilkan 73,5%.
Net saved revenue metrik bisnis	Churner yang dihubungi × tagihan bulanan × 12 bulan × success rate 30%, dikurangi biaya penawaran USD 35,15 per kontak.
Lift pada top-20% metrik operasional	Berapa kali lebih tepat sasaran dibanding menghubungi pelanggan secara acak, pada kapasitas yang sama.

Data relatif bersih, dan semua masalahnya diperbaiki tanpa membuang satu baris pun

7.043 pelanggan, **21** kolom: profil, layanan, kontrak, tagihan, dan target *Churn*.

Tidak ada nilai NaN, duplikat customerID, maupun outlier IQR.

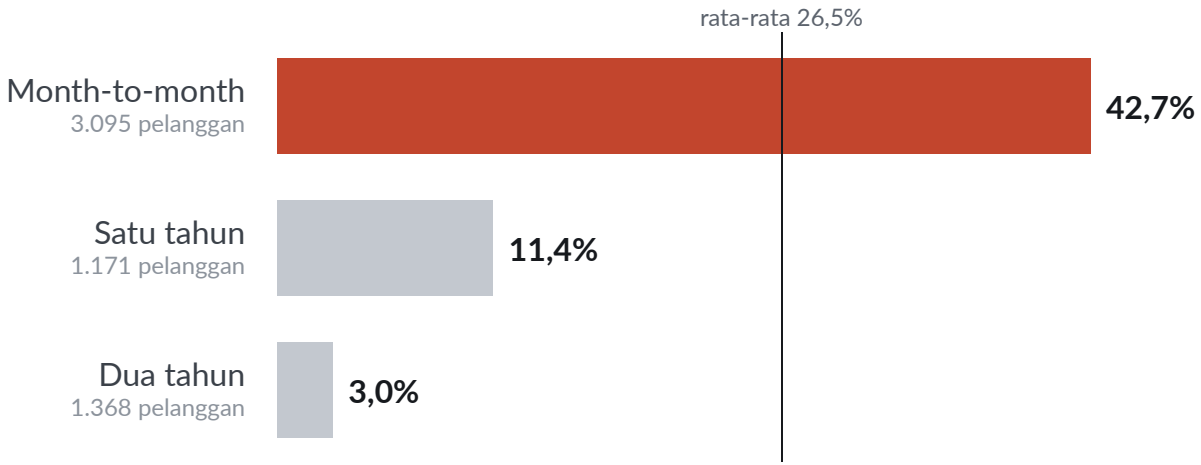
Data sampel IBM yang meniru kondisi bisnis nyata. Satu snapshot, tanpa tanggal.

Masalah yang ditemukan	Penanganan dan alasan
11 nilai `TotalCharges` kosong, semuanya pelanggan baru (tenure 0)	Diisi 0, karena pelanggan baru memang belum pernah ditagih
Kategori "No internet service" dan "No phone service" di 7 kolom layanan	Digabung ke "No"; informasinya sudah ada di `InternetService` dan `PhoneService`
22 baris identik di luar ID (pelanggan berbeda, profil sama)	Dipertahankan, lalu dijadikan satu grup saat split agar tidak muncul di train sekaligus test
27 baris dengan TotalCharges menyimpang > 25% dari tenure × tagihan	Dipertahankan karena tarif bisa berubah; menjadi dasar fitur `charge_increase`
Kelas tidak seimbang, churn 26,5%	Metrik PR-AUC, bobot kelas, dan aturan kapasitas top-20%

Pelanggan month-to-month churn 14 kali lebih sering daripada pelanggan kontrak dua tahun

Churn rate per jenis kontrak

Persentase pelanggan yang berhenti, data train (n = 5.634)



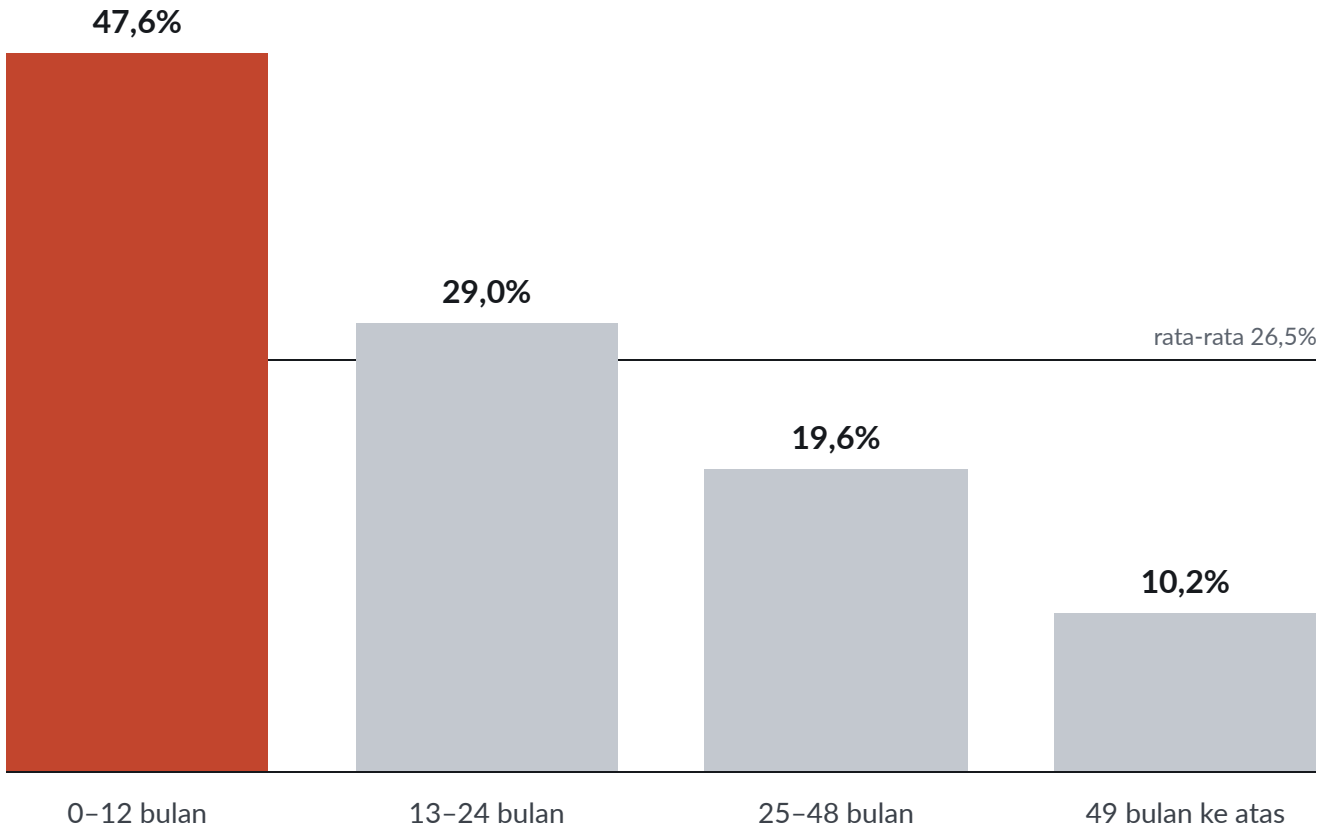
Implikasi

Month-to-month adalah segmen terbesar (55% pelanggan) sekaligus paling berisiko. Begitu pelanggan terikat kontrak, risikonya turun tajam. Jenis kontrak adalah tuas retensi paling kuat, dan menjadi dasar rekomendasi migrasi ke kontrak satu tahun.

Risiko churn terkonsentrasi di tahun pertama berlangganan

Churn rate per lama berlangganan

Data train (n = 5.634)



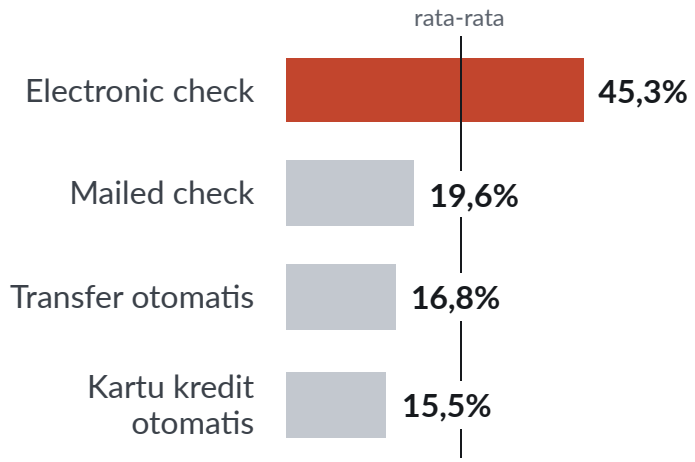
Implikasi

Median lama berlangganan pelanggan yang churn hanya **10 bulan**, dibanding **37 bulan** pada yang bertahan. Risiko di tahun pertama 4,7 kali risiko pelanggan lama. Onboarding dan kontak proaktif di 12 bulan pertama memberi peluang retensi terbesar.

Pembayaran electronic check dan layanan fiber optic menandai pelanggan yang paling mudah pergi

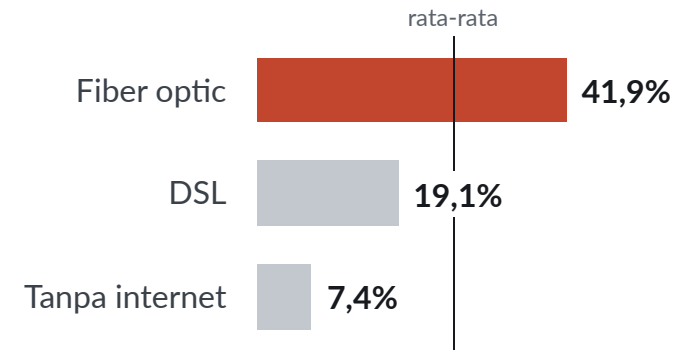
Churn rate per metode pembayaran

Data train



Churn rate per layanan internet

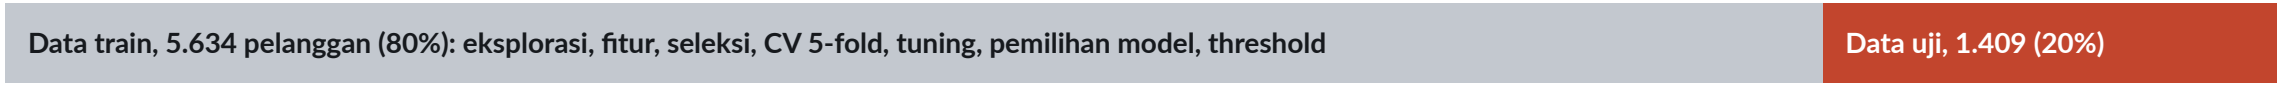
Data train



Implikasi

Kombinasi month-to-month dan electronic check mencatat churn **53,4%** dan mencakup 25,9% pelanggan. Di antara pengguna internet, churn turun dari 54,4% (tanpa add-on) ke 6,4% (enam add-on). Pembayaran otomatis dan bundling layanan menaikkan biaya untuk pindah.

Data uji disisihkan sejak awal dan baru dibuka setelah semua keputusan dikunci



Split stratified berbasis grup dilakukan sebelum eksplorasi data, sehingga 22 baris identik tidak terpecah ke dua sisi.

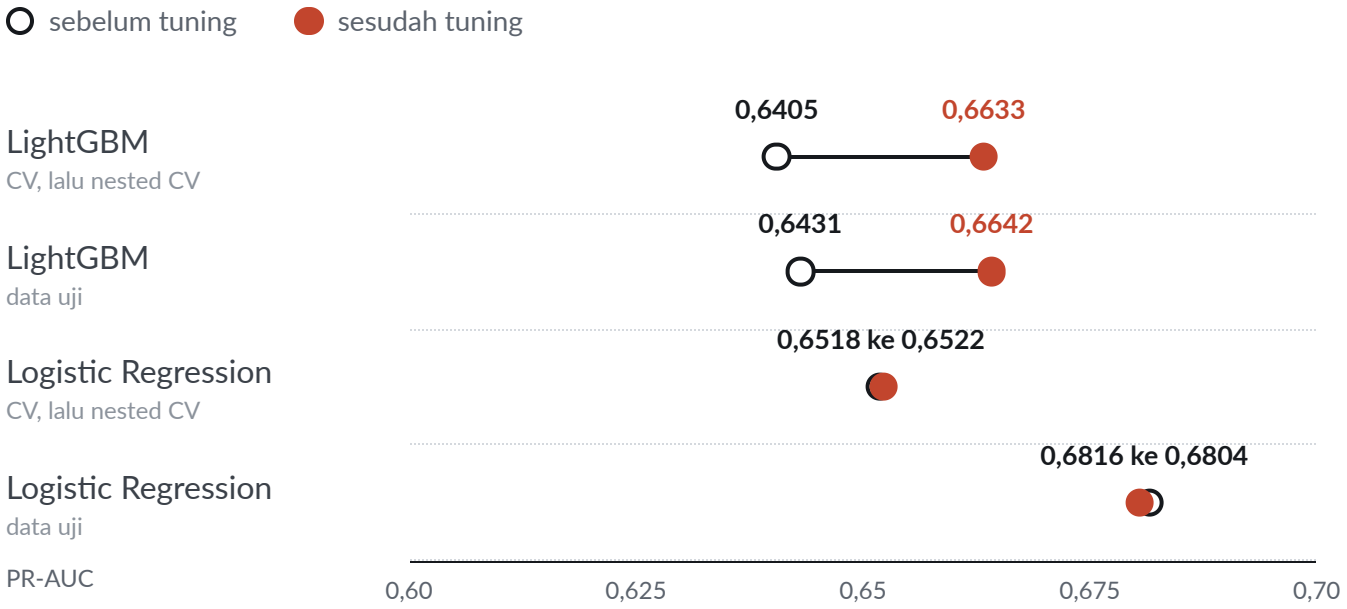
1. **Cleaning per baris.** Konversi tipe, isi nilai kosong, gabung kategori, tanpa statistik dari baris lain.
2. **Delapan fitur baru**, dihitung per baris di dalam pipeline. Satu dibuang karena kolinear; 25 fitur final.
3. **Pipeline dan CV 5-fold.** Encoder dan scaler di-fit ulang di setiap fold; semua model memakai fold yang sama.
4. **Tuning dengan nested CV**, agar skor sesudah tuning tidak bias optimis.
5. **Imbalance.** Bobot kelas, ditambah aturan operasional: hubungi 20% skor tertinggi. Threshold 0,5 ditolak karena menandai 41% pelanggan.
6. **Kunci keputusan.** Model final dan aturan kapasitas ditetapkan dari skor out-of-fold data train.
7. **Evaluasi akhir.** Data uji dibuka sekali; semua model dievaluasi dan keputusan tidak diubah.

Semua model machine learning 1,6 kali lebih tepat sasaran daripada aturan berbasis kontrak

Model	PR-AUC, data uji	PR-AUC, CV	Precision pada top-20%	Waktu fit	Interpretabilitas
Dummy (acak)	0,2654	0,2654	24,8%	0,04 dtk	tinggi
Aturan: kontrak saja	0,4173	0,4150	40,1%	0,02 dtk	tinggi
Random Forest	0,6066	0,6162	65,2%	0,58 dtk	rendah
LightGBM	0,6431	0,6405	68,1%	0,12 dtk	rendah–sedang
Logistic Regression	0,6816	0,6518	69,5%	0,07 dtk	tinggi (odds ratio)
Logistic Regression, tuned	0,6804	0,6522	69,9%	1,22 dtk	tinggi (odds ratio)
LightGBM, tuned (model final)	**0,6642**	**0,6633**	**67,7%**	**0,31 dtk**	**rendah–sedang**

PR-AUC 0,66 berbanding 0,27 untuk pilihan acak. Precision 67,7% berarti dua dari tiga pelanggan yang dihubungi memang akan churn. CV adalah rata-rata lima fold data train dan menjadi dasar keputusan; data uji dibuka sekali. Waktu fit diukur sekali dan bisa sedikit berbeda antar eksekusi.

Tuning menaikkan PR-AUC LightGBM sebesar 0,023, sementara Logistic Regression sudah mentok



Metode

RandomizedSearchCV dengan target PR-AUC: 40 kombinasi untuk LightGBM, 30 untuk Logistic Regression. Skor sesudah tuning diukur dengan nested CV.

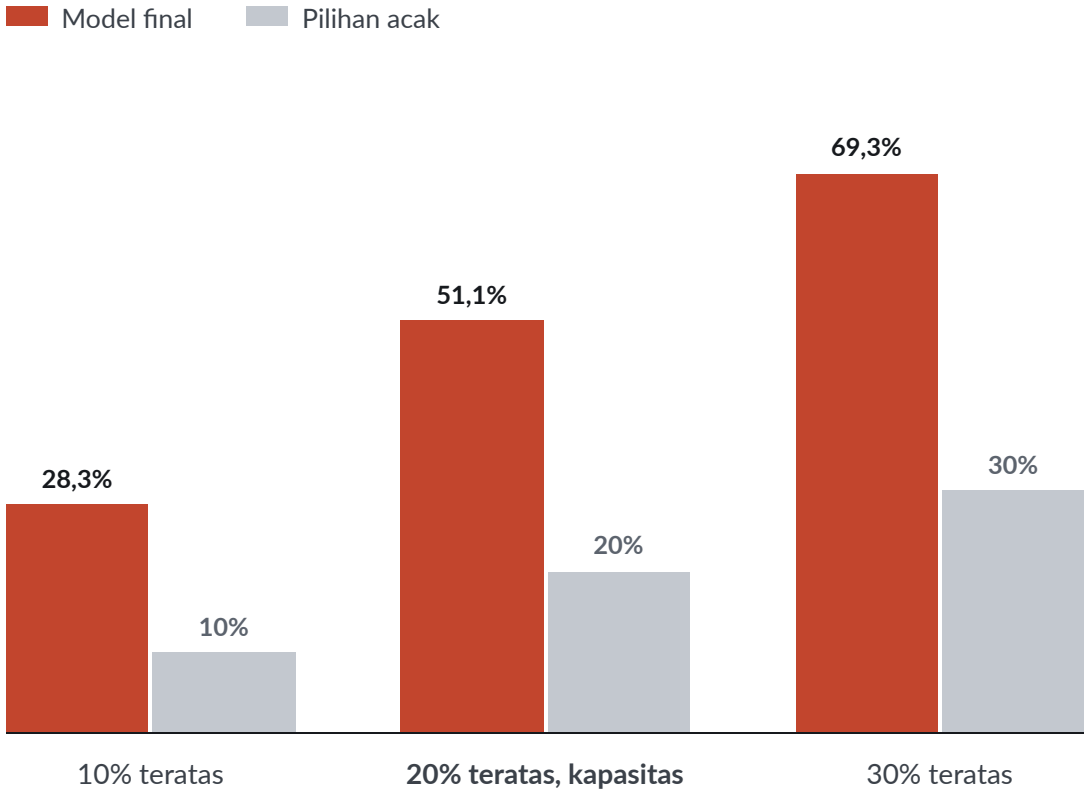
Parameter terbaik LightGBM

Pohon sangat dangkal (6 daun), learning rate 0,014, 307 pohon, regularisasi L2 4,82. Pengaturan bawaan terlalu kompleks untuk sekitar 5.600 baris data.

Dengan menghubungi 20% pelanggan berisiko tertinggi, model menangkap 51% dari semua churner

Persentase churner yang tertangkap

Menurut persentase pelanggan yang dihubungi, data uji (374 churner)



	Dihubungi	Tidak dihubungi
Churn	**191** tertangkap	**183** lolos
Bertahan	**91** salah sasaran	**944** benar dilewati

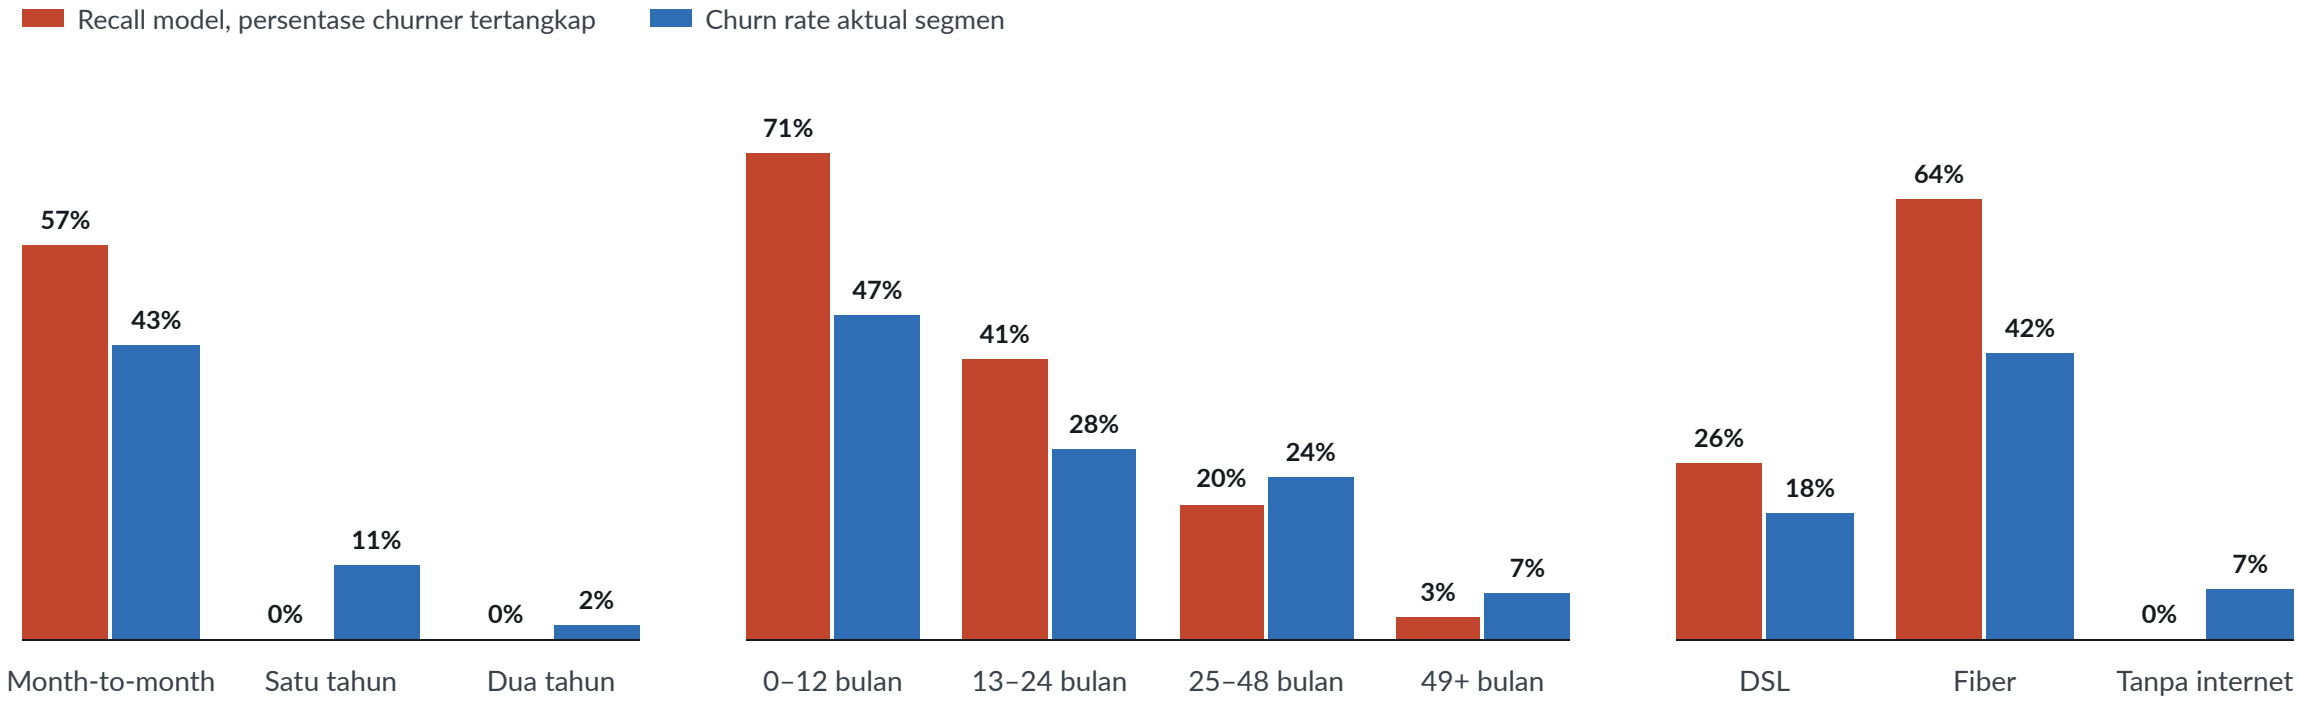
Precision **67,7%**: dua dari tiga kontak tepat sasaran. Lift **2,55 kali** dibanding acak, dan 2,83 kali pada 10% teratas.

Mengapa LightGBM

Aturan yang dikunci sebelum data uji dibuka: pilih PR-AUC CV tertinggi, kecuali Logistic Regression berada dalam selisih 0,01. Selisihnya 0,0111. Di data uji Logistic Regression justru unggul 0,016, masih dalam variasi antar-fold (±0,019), sehingga model itu dipantau sebagai challenger.

Aturan kapasitas setara skor ≥ 0,7221. Recall 51,1%, F1 0,582, ROC-AUC 0,8577, PR-AUC 0,6642.

Churner berkontrak panjang dan yang sudah lama berlangganan lolos dari radar model

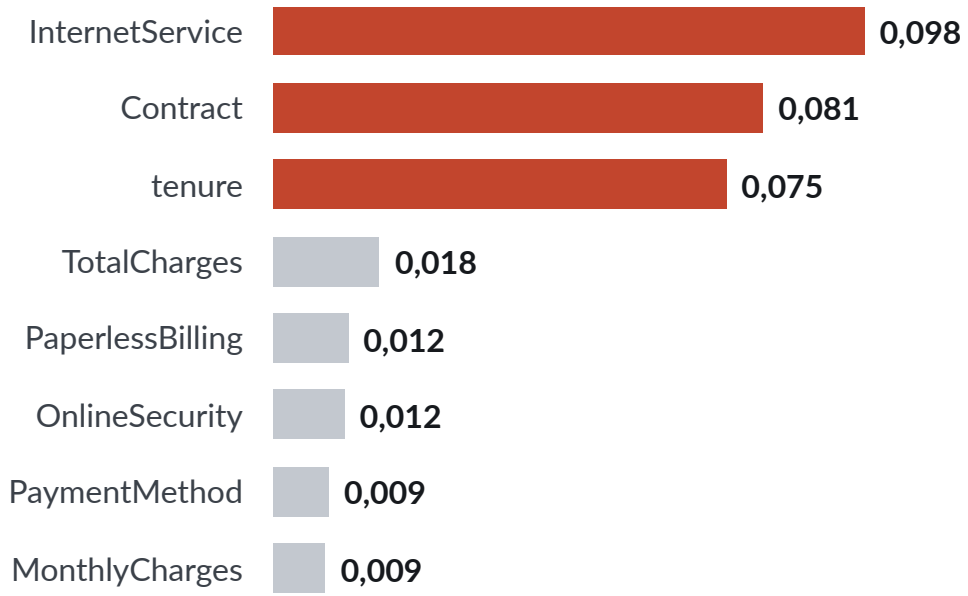


183 churner lolos. Median lama berlangganan mereka 24 bulan, dibanding 4 bulan pada yang tertangkap; 78% month-to-month (yang tertangkap 100%) dan 52% fiber (yang tertangkap 88%). Satu churner yang lolos merugikan sekitar USD 232, sedangkan satu kontak yang salah sasaran hanya USD 35. Pelanggan berkontrak panjang butuh program ringan tersendiri, misalnya pengingat sebelum kontrak habis, dan data keluhan.

Jenis layanan internet, kontrak, dan lama berlangganan paling menentukan risiko churn

Seberapa besar model bergantung pada setiap kolom

Penurunan PR-AUC saat kolom diacak, model final, data uji



Faktor	Arah efek (odds ratio)	Arti bisnis
Internet	Fiber 3,23 kali dibanding DSL	Ada masalah nilai atau kualitas di paket fiber
Kontrak	Dua tahun 0,21 kali, satu tahun 0,46 kali	Kontrak panjang memangkas odds churn 54–79%
Tenure	0,24 kali per tambahan 24,5 bulan	Tahun pertama adalah periode kritis
TotalCharges	1,73 kali per kenaikan 1 SD	Pada tenure sama, tagihan naik berarti risiko naik
Paperless billing	1,36 kali	Sinyal pelanggan yang mudah pindah

Odds ratio diambil dari Logistic Regression (tuned) sebagai model pendamping untuk membaca arah efek. Efeknya kondisional dan tidak kausal. Kategori acuan: DSL dan month-to-month.

Kampanye berbasis model menjadi prioritas pertama, dengan nilai USD 229 ribu per siklus

1	**Hubungi 20% pelanggan dengan skor risiko tertinggi setiap bulan** 1.410 pelanggan per siklus. Lebih baik USD 125.657 dibanding memprioritaskan berdasarkan kontrak saja.	229.338 USD per siklus
2	**Tawarkan migrasi ke kontrak satu tahun dengan diskon bulan pertama** 3.869 pelanggan month-to-month; churn 43% dibanding 11% pada kontrak satu tahun.	69.152 USD per siklus
3	**Perluas kapasitas kontak dari 20% ke 30% lewat kanal murah seperti SMS dan e-mail** 704 pelanggan tambahan per siklus. Kurva profit baru mendatar sekitar 56%.	68.570 USD per siklus
4	**Beri insentif USD 10 untuk pindah dari electronic check ke auto-debit** 2.315 pelanggan; churn 45% dibanding 16% pada pembayaran otomatis.	57.029 USD per siklus

Asumsi: success rate retensi 30%, horizon revenue 12 bulan, biaya penawaran USD 35,15 per kontak (diskon 50% dari median tagihan, satu bulan). Rekomendasi 2 dan 4: adopsi 20%, dan hanya separuh selisih churn rate dianggap efek program karena datanya observasional. Basis 7.043 pelanggan. Segmen saling beririsan, sehingga nilainya tidak boleh dijumlahkan. Lingkup rekomendasi 1 dihitung dari data uji.

Kampanye tetap menguntungkan di semua skenario, bahkan jika biaya penawaran naik empat kali

Net saved revenue kampanye, USD per siklus

Baris: kapasitas kontak. Kolom: success rate retensi. Bingkai: skenario dasar.

Kapasitas	20%	30%	40%
10%	81.621	134.818	188.016
20%	136.376	229.338	322.300
30%	173.832	297.909	421.985

Jika anggaran dipotong setengah

Kapasitas turun dari 20% ke 10%, nilainya turun ke USD 134.818. Itu hanya 41% lebih rendah, karena 10% teratas adalah pelanggan dengan precision tertinggi (75,2%).

Jika biaya penawaran naik

Dua kali lipat (USD 70): USD 179.791. Empat kali lipat (USD 141): USD 80.696. Precision break-even hanya 13,1%, jauh di bawah precision model 67,7%.

Model siap dipakai, tetapi asumsi bisnisnya harus divalidasi lewat pilot dengan grup kontrol

Keterbatasan

1. Data sampel IBM berupa satu snapshot tanpa tanggal, sehingga belum bisa divalidasi berbasis waktu.
2. Success rate, biaya, dan tingkat adopsi masih asumsi; rekomendasi 2 dan 4 berbasis korelasi.
3. LightGBM dan Logistic Regression setara secara statistik; urutannya berbalik antara CV dan data uji.
4. Churner berkontrak panjang sulit ditangkap tanpa data keluhan dan pemakaian.

Langkah berikutnya

1. **Pilot** kampanye dengan 10% grup kontrol acak untuk mengukur success rate yang sebenarnya.
2. **Scoring bulanan**, sekitar 19 detik untuk satu juta pelanggan. Retrain tiap kuartal atau saat PSI melewati 0,2 (sekarang 0,0145).
3. **Champion dan challenger.** Logistic Regression menggantikan LightGBM bila unggul PR-AUC minimal 0,01 selama tiga bulan berturut-turut.
4. **Data tambahan:** keluhan, kualitas jaringan, dan histori bulanan, lalu uplift modeling.

Pengungkapan penggunaan AI

Alat	Dipakai untuk	Cara verifikasi
Claude Code (Anthropic)	Menyusun rencana kerja dan checklist rubrik dari panduan UAS	Dicocokkan manual dengan bagian 3.2–3.8 dan 5 panduan
Claude Code	Membangun kode notebook, menjalankan eksperimen, menulis draf insight dari output	Notebook dijalankan ulang beberapa kali dengan hasil identik; setiap angka di insight dicocokkan dengan output sel; grafik diperiksa visual
Claude Code, code review	Review kode notebook; 10 temuan diperbaiki (split berbasis grup, nested CV, aturan top-k tunggal, permutation importance per kolom asli)	Setiap temuan dicek terhadap kode sebelum diperbaiki; hasil dibandingkan sebelum dan sesudah
Claude Code, humanizer	Menulis ulang prosa notebook dan deck agar lebih natural	Output notebook dibandingkan sebelum dan sesudah; angka tidak berubah
Claude Code	Menyusun draf deck ini (PDF dan PPTX) dari output notebook	Setiap angka di deck dicek silang dengan output notebook
Claude Code, audit akhir	Review kode dan audit submission terhadap rubrik; label dan sel insight dilengkapi	Notebook dijalankan ulang dua kali; angka model identik, hanya waktu eksekusi berbeda; angka deck dicek otomatis

Seluruh keputusan analisis, interpretasi, dan rekomendasi telah dibaca, diperiksa, dan dipertanggungjawabkan oleh mahasiswa. Tidak ada data eksternal yang dipakai dan tidak ada notebook publik yang disalin.

Detail teknis: fitur baru, parameter, dan asumsi bisnis

Fitur baru	Definisi
`n_addon_services`	Jumlah layanan add-on internet yang aktif (0–6)
`avg_charge_per_month`	TotalCharges dibagi tenure; dibuang karena korelasi 0,996 dengan MonthlyCharges
`charge_increase`	MonthlyCharges dikurangi rata-rata tagihan historis
`tenure_group`	0–12, 13–24, 25–48, dan 49+ bulan
`is_auto_payment`	Transfer bank atau kartu kredit otomatis
`mtm_echeck`	Month-to-month dan electronic check
`no_protection`	Fiber tanpa OnlineSecurity dan TechSupport
`family_flag`	Memiliki partner atau tanggungan

Asumsi bisnis	Nilai
Kapasitas tim retensi per siklus	20%
Success rate retensi	30%
Horizon revenue	12 bulan
Biaya penawaran (50% median tagihan train, satu bulan)	USD 35,15
Adopsi program rekomendasi 2 dan 4 / porsi efek kausal	20% / 50%
Insentif auto-debit	USD 10

LightGBM final: n_estimators 307, learning_rate 0,014, num_leaves 6, min_child_samples 57, subsample 0,7618, colsample_bytree 0,5132, reg_lambda 4,8203, scale_pos_weight 2,769. **Logistic Regression tuned:** C 35,2048, l1_ratio 0,75, class_weight balanced. **Reproducibility:** RANDOM_STATE 42, split dan fold berbasis grup, dijalankan ulang dengan hasil identik. Kode, notebook, dan data: github.com/titan2903/uas-predictive-analytics.

Log eksperimen, termasuk yang gagal

Eksperimen	Hasil (PR-AUC)	Status	Pelajaran
Bobot kelas (LR)	0,6531 ke 0,6509; recall pada 0,5 naik dari 0,522 ke 0,796	gagal sebagian	Imbalance adalah masalah keputusan, bukan ranking
Delapan fitur baru	LR 0,6507 ke 0,6509; LightGBM 0,6396 ke 0,6397	gagal	Tidak menaikkan skor; tetap dipakai karena bermakna bisnis
Seleksi fitur	Partner dan avg_charge_per_month dibuang; naik 0,0008	berhasil	Model lebih sederhana dengan performa setara
Tuning LightGBM	Nested CV 0,6405 ke 0,6633; data uji 0,6431 ke 0,6642	berhasil	Regularisasi mengurangi overfit
Tuning Logistic Regression	Nested CV 0,6518 ke 0,6522; data uji 0,6816 ke 0,6804	gagal	Batas performa ada di data, bukan di tuning
Threshold 0,5	Menandai 41% pelanggan, padahal kapasitas 20%	gagal	Tidak bisa dijalankan; diganti aturan 20% teratas
Random Forest bawaan	0,6162, dibanding LR 0,6518	gagal	Overfit pada sekitar 5.600 baris
Pemilihan model	CV: LightGBM unggul 0,0111; data uji: LR unggul 0,0162	setara	Keputusan dikunci; LR menjadi challenger